INFLUÊNCIA DO LIMIAR DE DECISÃO NA CLASSIFICAÇÃO DE TUMORES MAMÁRIOS: COMPARAÇÃO ENTRE MLP E REGRESSÃO LOGÍSTICA

INFLUENCE OF DECISION THRESHOLDS ON BREAST TUMOR CLASSIFICATION: MLP VERSUS LOGISTIC REGRESSION

Alane Damasceno Moreno
Bacharelado em Ciência da Computação – IFCE, Campus Aracati
Inteligência Artificial – Prof. Gabriel Duarte

1 PROBLEMA DE PESQUISA

A classificação supervisionada de tumores mamários pode apresentar elevado desempenho global e, ainda assim, deixar de identificar parte dos casos malignos. Nesses problemas, falsos negativos merecem análise específica, pois a acurácia isolada não expressa a distribuição dos erros. O conjunto Breast Cancer Wisconsin Diagnostic, disponibilizado no *scikit-learn*, fornece dados públicos para experimentos controlados com 569 amostras e 30 atributos.

Srinivasu et al. (2024) investigaram uma combinação de CatBoost e MLP, enquanto Bamodu, Nezam e Chung (2026) compararam oito algoritmos e discutiram interpretabilidade e calibração de probabilidades. A pergunta deste projeto é: *como a variação do limiar de decisão afeta o recall, o F1-score e os falsos negativos de uma MLP e de uma Regressão Logística, sob o mesmo protocolo experimental?*

2 JUSTIFICATIVA

O limiar padrão de 0,5 não necessariamente produz a melhor relação entre sensibilidade e falsos positivos em todas as tarefas. Comparar decisões obtidas a partir das mesmas probabilidades permite evidenciar a diferença entre qualidade de ordenação (ROC-AUC) e classificação em um ponto operacional. O estudo utiliza ferramentas públicas, sem pretender criar um sistema de diagnóstico clínico. A lacuna é tratada como *recorte analítico entre os estudos selecionados*, não como alegação de ineditismo absoluto.

3 OBJETIVO GERAL

Analisar o efeito da variação do limiar de decisão sobre a identificação de tumores malignos em modelos de Regressão Logística e MLP treinados no mesmo conjunto de dados.

4 OBJETIVOS ESPECÍFICOS

1. Implementar pipelines equivalentes de treinamento e validação para Regressão Logística e MLP.
2. Comparar limiares de 0,1 a 0,9 quanto a falsos negativos, falsos positivos, recall e F1-score.
3. Avaliar ROC-AUC e matrizes de confusão, discutindo o compromisso entre sensibilidade e precisão.
4. Identificar limitações metodológicas e possibilidades de replicação do estudo.

Tabela 1 – Síntese do problema e das decisões de pesquisa

Dimensão	Delimitação adotada
Problema	Efeito do limiar de decisão sobre a identificação de malignidade.
Comparação	Regressão Logística (referência) e MLP (modelo neural).
Foco analítico	Recall, F1-score e número de falsos negativos.
Escopo	Estudo acadêmico com base pública, sem aplicação clínica.

Fonte: elaboração própria (2026).

5 METODOLOGIA

Será realizado um estudo quantitativo, aplicado e experimental, em Python no Google Colab (CPU), com *scikit-learn*. Os dados públicos Breast Cancer Wisconsin Diagnostic (UCI, disponibilizados pelo *scikit-learn*) serão carregados por `load_breast_cancer`, com 569 observações, 30 atributos e duas classes; serão verificadas as condições de licença e citação na fonte original. A codificação será ajustada para 1 = maligno (classe positiva) e 0 = benigno. A divisão treino–teste será estratificada (80/20, semente 42). O `StandardScaler` será ajustado apenas ao treino, dentro de *Pipeline*, prevenindo vazamento de dados. A Regressão Logística será o *baseline*; a MLP será o comparador neural. A avaliação incluirá validação cruzada estratificada de cinco partições no treinamento.

Serão obtidas probabilidades fora da amostra na validação cruzada para descrever os limiares de 0,1 a 0,9. O critério exploratório de seleção será o maior F1 da classe maligna no treino, com desempate pelo menor limiar; o conjunto de teste permanecerá reservado para uma única avaliação final dessa regra. Serão apresentadas matriz de confusão, falsos negativos/positivos, recall, precisão, F1-score e ROC-AUC. Será comparado o limiar padrão ao selecionado, sem interpretação clínica.

Tabela 2 – Protocolo experimental previsto

Componente	Procedimento
Base e divisão	Wisconsin Diagnostic: 569 amostras, 30 atributos; treino/teste estratificado 80/20 (semente 42).
Pré-processamento	Padronização dentro do *Pipeline*, ajustada apenas aos dados de treinamento.
Modelos	`LogisticRegression` e `MLPClassifier`.
Validação	Cinco partições estratificadas nos dados de treino.
Análise	Limiares de 0,1 a 0,9; matriz de confusão, precisão, recall, F1 e ROC-AUC.
Ambiente	Python, *scikit-learn* e Google Colab (CPU).

Fonte: elaboração própria (2026).

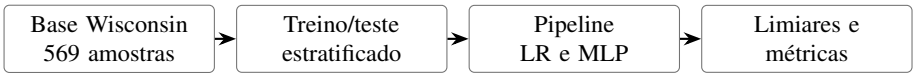


Figura 1 – Fluxo previsto para o experimento comparativo.

Fonte: elaboração própria (2026).

6 RESULTADOS ESPERADOS

Espera-se produzir um notebook reproduzível, tabelas comparativas e gráficos que mostrem como o limiar altera os erros e as métricas dos dois classificadores. O êxito será definido pela execução reproduzível do protocolo e por uma discussão fundamentada das diferenças observadas, independentemente de qual algoritmo obter a maior pontuação.

7 RISCOS E LIMITAÇÕES

A amostra é relativamente pequena, utiliza um único conjunto público e não representa diversidade de contextos clínicos. A seleção de limiar por validação interna pode variar com as partições; portanto, os resultados não serão generalizados para prática médica. Se a MLP apresentar instabilidade, será adotada configuração previamente definida.

8 DECLARAÇÃO DE USO DE INTELIGÊNCIA ARTIFICIAL

O Hermes Agent, conectado à OpenRouter, foi utilizado para auxiliar na localização e triagem inicial de referências científicas. Ferramentas de IA também auxiliaram na revisão linguística, incluindo correção ortográfica, coesão gramatical e ajustes estilísticos, e o apoio à organização lógica dos argumentos, com atenção à integridade acadêmica e sob supervisão e revisão da autora. As sugestões incorporadas ao texto foram examinadas e revisadas pela autora, que assume integralmente a responsabilidade pelo

conteúdo final, pelas escolhas metodológicas, pelos argumentos e pelas conclusões apresentados. Não foram compartilhadas informações inéditas, dados sensíveis ou conteúdos originais de terceiros com as plataformas utilizadas. Esses cuidados foram adotados visando ao respeito aos direitos autorais e à proteção de dados pessoais, considerando a Lei Geral de Proteção de Dados Pessoais (LGPD — Lei nº 13.709/2018). Declaro que li e conferi pessoalmente as referências citadas neste documento, verificando sua identificação bibliográfica e a correspondência entre as afirmações e as fontes originais.

REFERÊNCIAS

SRINIVASU, P. N. et al. XAI-driven CatBoost multi-layer perceptron neural network for analyzing breast cancer. *Scientific Reports*, v. 14, art. 28674, 2024. DOI: 10.1038/s41598-024-79620-8.

BAMODU, O. A.; NEZAM, S.; CHUNG, C.-C. Explainable machine learning for breast cancer prediction in resource-constrained settings. *PLOS Digital Health*, v. 5, n. 9, e0001706, 2026. DOI: 10.1371/journal.pdig.0001706.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *JMLR*, v. 12, p. 2825–2830, 2011.

SCIKIT-LEARN DEVELOPERS. *Breast cancer Wisconsin (diagnostic) dataset*. Disponível em: <https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_breast_cancer.html>. Acesso em: 22 out. 2026.